

SII-Agent 自进化任务求解实验报告

从初始不收敛到 BrowseComp-Plus 全量可打榜

SII-Agent / Qwen3.5-9B

2026-05-13

摘要

本报告总结了本轮从 SimpleQA、2Wiki 到 BrowseComp-Plus 的完整实验过程。系统最初存在模型反复搜索、不提交最终答案、BrowseComp 固定语料检索未接入、反思可能泄漏 gold answer、局部字符串评分偏宽等问题。经过 ReAct/Harness 收敛控制、严格评分、固定语料 BM25 检索、无 gold 反思、长期记忆与 batch-wise test-time evolution 等改造后，系统在 SimpleQA、2Wiki 和 BrowseComp-Plus 上均表现出相对 baseline 的提升。BrowseComp-Plus 全量 830 题使用 Qwen3-32B 作为 LLM-as-judge 评测，baseline 准确率为 25.54%，ours/evolved 为 31.57%，同时 evidence recall 从 31.65% 提升到 40.95%。

1 实验目标

本轮工作的目标是实现夏令营赛题要求中的自进化任务求解 Agent，并进行可复现实验：

- 实现工具增强的 ReAct Agent，包括搜索、浏览和最终答案提交工具。
- 引入 Harness，对最大步数、超时、重复工具调用、工具白名单和最终收敛进行控制。
- 实现 Reflection 与 Memory，让系统能够在测试时从失败轨迹中总结策略。
- 在 SimpleQA 和 2Wiki 上比较 baseline 与 evolved。
- 接入 BrowseComp-Plus 固定语料库，生成 leaderboard-compatible run files，并用 Qwen3-32B 进行 LLM-as-judge 评测。

2 方法概述

2.1 Retriever

BrowseComp-Plus 实验中使用的 retriever 是 **BM25**，实现方式为 SQLite FTS5：

- 语料：Tevatron/browsecomp-plus-corpus 官方固定 corpus。
- 索引：data/browsecomp-plus/browsecomp_fts.sqlite。
- 排序：SQLite FTS5 的 bm25(docs_fts, 1.0, 0.2)。
- 工具：browsecomp_search(query, k) 与 browsecomp_get_document(docid)。

这一路径只检索 BrowseComp-Plus 提供的固定文档库，不使用开放互联网搜索。与 Qwen3-Embed-8B 等 dense retriever 相比，BM25/FTS5 不需要 embedding 模型、GPU 或向量库，因此成本更低，但召回上限通常低于强 dense retriever。

2.2 ReAct + Harness

核心解题循环为：

1. 模型根据问题生成一个工具调用。
2. 工具返回检索结果或文档内容。
3. 模型根据累积证据继续搜索、读取文档或提交最终答案。

Harness 负责以下约束：

- 最大步数、总 wall time、单次 LLM 调用 timeout。
- 工具白名单, BrowseComp 只允许 `browsecomp_search`, `browsecomp_get_document`, `final_answer`。
- 重复工具调用检测，避免同一 query 反复搜索。
- 最后一步强制只开放 `final_answer`，工具预算耗尽后进行 forced finalization。

2.3 Reflection 与 Memory

Evolved 模式在 baseline ReAct 之上加入：

- **Reflection**：失败或未完成后，模型根据轨迹总结 failure mode、root cause、corrective strategy 与 reusable lesson。
- **Memory**：将 episode 与 lesson 写入 JSONL 文件，并在后续 batch 中检索相关 lesson 放入 prompt。
- **Retry**：当一次尝试失败时，将 reflection 作为 retry hint，再进行一次解题。

本次 BrowseComp evolved 使用的是 benchmark-local test-time evolution memory，即从空 memory 开始，在 BrowseComp 内部按 batch 积累经验。它不是跨 benchmark 预先积累的长期 prior memory，也没有更新模型参数。默认不将 gold answer 传给 reflection，并且写入 memory 前会 redaction，避免答案泄漏。

3 从不工作到可工作的关键修复

初始系统在 smoke test 中出现了多个问题：

- Qwen3.5-9B 倾向于不断调用 search, 不提交 `final_answer`, SimpleQA smoke 出现 0% accuracy, `stop_reason=max_steps`。
- 原评分逻辑使用宽松 substring matching，可能虚高准确率。
- Reflection 如果直接看到 expected answer，会造成长期 memory 泄漏 gold。
- BrowseComp-Plus 需要固定 corpus docid，而不是普通网页或 wiki25 docid。

- 长上下文高并发时，单卡 9B vLLM 发生 `APITimeoutError`。

对应修复如下：

- 将最后一步工具限制为 `final_answer`，并加入工具预算耗尽后的 `forced finalization`。
- 引入 `normalized exact match` 与 `token F1`，去掉宽松 `substring scoring`。
- `Reflection` 默认不接收 `expected answer`；`memory` 中 `redaction gold answer`。
- 新增 `BrowseComp-Plus FTS5 index builder`、检索工具与 `official-compatible run writer`。
- 将 9B vLLM 重启到 GPU 0 和 GPU 3，`tensor-parallel-size=2`，并发提升到 128。

4 实验设置

项目	设置
解题模型	Qwen/Qwen3.5-9B, vLLM, OpenAI-compatible API
BrowseComp judge	Qwen/Qwen3-32B, LLM-as-judge, <code>enable_thinking=false</code>
BrowseComp retriever	BM25, SQLite FTS5 over fixed BrowseComp-Plus corpus
SimpleQA/2Wiki 并发	16
BrowseComp 并发	128
BrowseComp 样本数	830 / full set
BrowseComp max steps	10
BrowseComp memory	evolved 使用 fresh benchmark-local memory, batch size 128

表 1: 主要实验设置

5 SimpleQA 与 2Wiki 结果

SimpleQA 与 2Wiki 使用本地 `exact/F1` 评分。Evolved 模式包含 `Reflection`、`Memory` 和 `retry`，且不使用 `gold reflection`。

任务	模式	样本数	Accuracy	Avg F1	Avg Tool Calls
SimpleQA	baseline	20	45.00%	0.503	4.25
SimpleQA	evolved	20	65.00%	0.736	3.40
2Wiki	baseline	20	30.00%	0.534	5.15
2Wiki	evolved	20	45.00%	0.624	5.05

表 2: SimpleQA 与 2Wiki baseline/evolved 对比

结果表明, evolved 在两个小规模文本 QA benchmark 上均优于 baseline。SimpleQA 中准确率提升 20 个百分点, 同时平均工具调用从 4.25 降至 3.40。2Wiki 中准确率提升 15 个百分点, 工具调用基本持平。

6 BrowseComp-Plus 结果

6.1 本地 exact/F1 统计

BrowseComp-Plus 先写出 official-compatible run JSON, 再计算本地 exact/F1 与 evidence recall。这部分不是最终 leaderboard 口径, 但可用于调试与 sanity check。

模式	样本数	Local Acc.	Completed	Evidence Recall	Avg Steps	Avg Tool Calls
baseline	830	16.27%	99.88%	31.65%	9.55	9.52
evolved	830	24.34%	99.76%	40.95%	9.57	9.53

表 3: BrowseComp-Plus 本地统计

6.2 Qwen3-32B LLM-as-judge 官方口径

最终使用 Qwen3-32B 按 BrowseComp-Plus 官方 judge prompt 评估答案等价性。Judge 使用 OpenAI-compatible chat endpoint, 并显式关闭 thinking。

模式	Accuracy	Recall	Search Calls	Calibration Error
baseline	25.54%	31.65%	7.89	66.88%
evolved	31.57%	40.95%	7.83	57.62%

表 4: BrowseComp-Plus 全量 830 题, Qwen3-32B LLM-as-judge 结果

Evolved 相比 baseline:

- Accuracy 从 25.54% 提升到 31.57%, 提升 6.03 个百分点。
- Evidence Recall 从 31.65% 提升到 40.95%, 提升 9.30 个百分点。
- Search Calls 从 7.89 略降到 7.83, 说明提升不是靠更多搜索调用堆出来的。
- Calibration Error 从 66.88% 降到 57.62%, 说明 judge 提取到的 confidence 与正确率更一致。

7 结果解读

结果说明, 当前 evolved agent 的主要收益来自更好的 test-time 搜索策略, 而不是更贵的 retriever 或更多工具调用。BM25/FTS5 是低成本 retriever, 理论召回上限弱于 Qwen3-Embed-8B 等 dense retriever。但在相同 retriever 下, Reflection 与 Memory 能让后续 batch 避免重复低效搜索, 更倾向拆解日期、事件、实体和线索组合, 因此 evidence recall 明显提升。

同时，Search Calls 没有增加，说明 evolved 不是简单扩大搜索预算，而是提高了每次搜索的有效性。这与 SimpleQA/2Wiki 中工具调用下降或持平、准确率上升的现象一致。

8 局限与后续工作

- 当前 BrowseComp memory 是 benchmark-local test-time evolution，不是跨 benchmark 预训练 memory。
- Retriever 是 BM25/FTS5，成本低但召回上限有限。若换用 Qwen3-Embed-8B 或 hybrid retriever，可能进一步提高 recall。
- BrowseComp 中仍有极少数异常工具名残留计数，如 `web_search`、`wiki_search`、`browse_comp_search`，正式提交前应清洗为固定 corpus retriever 口径。
- Evolved 的提升来自 batch-wise test-time adaptation；若 leaderboard 严格要求每题完全独立，应在提交说明中标注 scaffold 为 custom。
- 后续可以先在 SimpleQA/2Wiki 或训练 split 上积累通用搜索 memory，再以 read-only 方式迁移到 BrowseComp，形成真正跨 benchmark 的 persistent memory。

9 主要产物路径

路径	内容
logs/eval/simpleqa_baseline_1778676754	SimpleQA baseline 结果
logs/eval/simpleqa_evolved_1778676815	SimpleQA evolved 结果
logs/eval/2wiki_baseline_1778676754	2Wiki baseline 结果
logs/eval/2wiki_evolved_1778676815	2Wiki evolved 结果
logs/eval/browsecomp_baseline_1778682823/runs	BrowseComp baseline official-compatible run JSON
logs/eval/browsecomp_baseline_1778682823/official_qwen32b_eval	Baseline Qwen3-32B judge 输出
logs/eval/browsecomp_evolved_1778685529/runs	BrowseComp evolved official-compatible run JSON
logs/eval/browsecomp_evolved_1778685529/official_qwen32b_live_eval	Evolved Qwen3-32B judge 输出

路径	内容
logs/eval/browsecomp_evolved_1778685529/leaderboard_submission_llm_judge.json	Evolved leaderboard submission JSON

10 结论

本轮实验从最初不收敛、无法稳定提交最终答案的状态，迭代到可以在 BrowseComp-Plus 全量 830 题上高并发生成并用 Qwen3-32B 完成 LLM-as-judge 评测。在 SimpleQA、2Wiki 和 BrowseComp-Plus 三类任务上，evolved agent 均优于 baseline。最关键的结论是：在低成本 BM25 retriever 不变的情况下，Reflection + Memory + Harness 约束带来的 test-time evolution 能够显著提升搜索召回与最终答案质量。